

Мегафакультет Трансляционных информационных технологий  
Факультет информационных технологий и программирования

## Лабораторная работа №4.

По дисциплине «Прикладная математика»

### Методы решения СЛАУ

Выполнили:

Студенты М32061

Величко Максим Иванович, 334786

Гусев Андрей Александрович, 336515

Бонет Станислав, 334349

Проверила:

Преподаватель практики

Гомозова Валерия Эдуардовна

---

## 1. Реализация метода Гаусса с выбором ведущего элемента для решения СЛАУ

Метод заключается в том, что приводит матрицу к ступенчатому виду, т. е. получение нулей под главной диагональю и нахождение неизвестных снизу вверх.

Числа, на которые производится деление в методе Гаусса, называются ведущими или главными элементами. Таким образом, в начале каждого этапа прямого хода решения системы следует добавить логику перестановки строк для выполнения приведенного условия.

Чтобы уменьшить влияние ошибок округления и исключить деление на нуль на каждом этапе прямого хода, уравнения системы переставляют так, чтобы деление проводилось на наибольший по модулю в данном столбце элемент.

```
4 def gaussian_elimination(A, b):
5     n = len(A)
6
7     # Прямой ход
8     for i in range(n):
9         # Выбор ведущего элемента
10        max_index = i
11        for j in range(i + 1, n):
12            if abs(A[j][i]) > abs(A[max_index][i]):
13                max_index = j
14        A[[i, max_index]] = A[[max_index, i]]
15        b[[i, max_index]] = b[[max_index, i]]
16
17        # Приведение матрицы к треугольному виду
18        for j in range(i + 1, n):
19            factor = A[j][i] / A[i][i]
20            A[j] -= factor * A[i]
21            b[j] -= factor * b[i]
22
23    # Обратный ход
24    x = np.zeros(n)
25    for i in range(n - 1, -1, -1):
26        x[i] = (b[i] - np.dot(A[i][i + 1:], x[i + 1:])) / A[i][i]
27
28    return x
```

Проведем исследование на системах с матрицами  $A^k$  :

Берем значения для  $k[1..3]$ , причем, генерируем матрицы такого вида,  $K = 1$ :

```
Matrix A^(k):
[[11.1 -2. -2. -4. -3. ]
 [-3. 11. -2. -4. -2. ]
 [-2. -3. 12. -3. -4. ]
 [-2. -4. -1. 10. -3. ]
 [-1. -4. -3. -3. 11. ]]
Condition number: 1008.588161192836
Gauss solution: [133.48766583 134.46987724 134.61390445 134.5383215 134.79741379]
Gauss error: 298.25173333433844
```

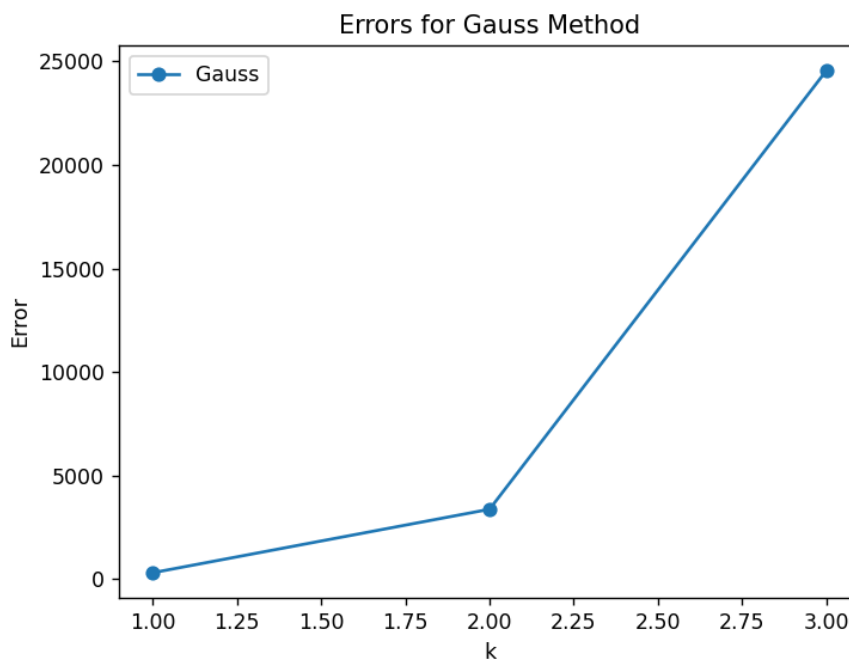
K = 2:

```
Matrix A^(k):  
[[11.01 -3. -1. -3. -4. ]  
 [-2. 10. -3. -4. -1. ]  
 [-1. -1. 7. -3. -2. ]  
 [-2. -1. -1. 8. -4. ]  
 [-3. -1. -3. -2. 9. ]]  
Condition number: 9593.956377472812  
Gauss solution: [1504.54247741 1505.7834803 1505.99524346 1505.77816088 1505.83312732]  
Gauss error: 3364.357894355949
```

K = 3:

```
Matrix A^(k):  
[[11.001 -3. -1. -4. -3. ]  
 [-1. 9. -4. -3. -1. ]  
 [-4. -3. 13. -4. -2. ]  
 [-4. -1. -4. 12. -3. ]  
 [-1. -2. -2. -3. 8. ]]  
Condition number: 93419.01785906446  
Gauss solution: [10984.12801004 10985.05397712 10984.88096171 10984.88503375  
 10985.26973679]  
Gauss error: 24560.620833425135
```

График зависимости ошибок от K



Число обусловленности квадратных матриц возрастает с увеличением параметра  $k$ , что приводит к ухудшению точности решения. Однако точность решения при использовании метода Гаусса с выбором ведущего элемента остается в среднем стабильной при изменении параметра  $k$  до определённого значения. Это объясняется тем, что данный метод позволяет избежать проблемы плохой обусловленности матрицы и гарантирует стабильность решения системы линейных уравнений. Погрешность решения увеличивается с увеличением числа обусловленности матрицы.

## 2. Реализация алгоритма LU – разложения с использованием разреженно – строчного формата хранения матрицы, а также метода решения СЛАУ с использованием LU – разложения.

Суть метода заключается в том, что матрица коэффициентов **A** представляется в виде произведения матриц **L** и **U**, где **L** – нижнетреугольная матрица, **U** – верхнетреугольная матрица, все диагональные элементы которой равны 1. Вектор **B** в ходе разложения не изменяется.

Алгоритм

1. Создаем матрицы

$$L = \begin{pmatrix} l_{1,1} & 0 & 0 \\ l_{2,1} & l_{2,2} & 0 \\ l_{3,1} & l_{3,2} & l_{3,3} \end{pmatrix}$$

и

$$U = A = \begin{pmatrix} 10 & -7 & 0 \\ -3 & 6 & 2 \\ 5 & -1 & 5 \end{pmatrix}$$

2. Для каждого столбца  $j = 1 \dots 3$  матрицы **L** будем вычислять  $l_{i,j}$  как

$$l_{i,j} = \frac{u_{j,j}}{u_{i,j}}$$

Для каждой строки  $c_i$  вычислим  $c_i = c_i - l_{i,j} \cdot c_j$

3. Выполняем шаг 2 пока  $j \leq 3$

4. Получем

$$L = \begin{pmatrix} 1 & 0 & 0 \\ l_{2,1} & 1 & 0 \\ l_{3,1} & l_{3,2} & 1 \end{pmatrix}$$

и

$$U = \begin{pmatrix} u_{1,1} & u_{1,2} & u_{1,3} \\ 0 & u_{2,2} & u_{2,3} \\ 0 & 0 & u_{3,3} \end{pmatrix}$$

Такие, что  $A = L \cdot U$

Вот код, который реализует данный алгоритм:

```
6 def lu_decomposition_sparse(A):
7     n = A.shape[0]
8     L = csr_matrix((n, n), dtype=float)
9     U = csr_matrix((n, n), dtype=float)
10
11     for k in range(n):
12         L[k, k] = 1.0
13         U[k, k] = A[k, k] - L[k, :k].dot(U[:k, k].toarray().flatten())
14
15         for j in range(k + 1, n):
16             U[k, j] = A[k, j] - L[k, :k].dot(U[:k, j].toarray().flatten())
17
18         for i in range(k + 1, n):
19             L[i, k] = (A[i, k] - L[i, :k].dot(U[:k, k].toarray().flatten())) / U[k, k]
20
21     return L, U
```

Проведем исследование на системах с матрицами  $A^k$  :

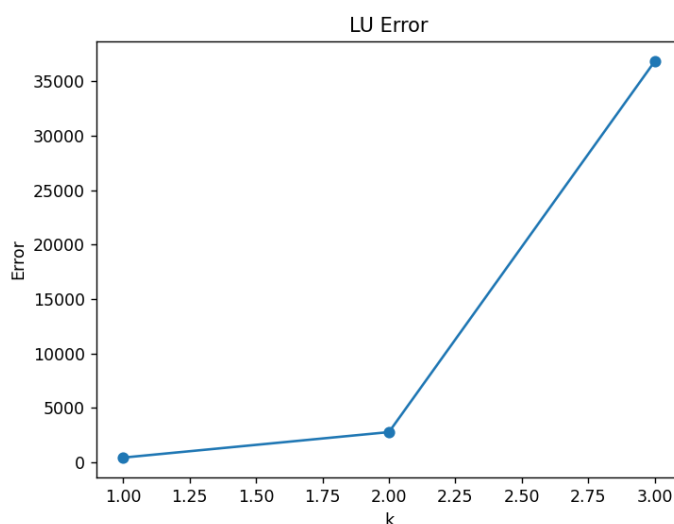
Берем значения для  $k[1..3]$ , причем, генерируем матрицы такого вида, как и методе Гаусса, но получаем уже такие результаты:

```
==== k = 1 ====  
Matrix A^(k):  
[[10.1 -3. -4. -1. -2. ]  
 [-3. 14. -4. -3. -4. ]  
 [-1. -2. 7. -3. -1. ]  
 [-4. -2. -1. 9. -2. ]  
 [-4. -4. -2. -3. 13. ]]  
Condition number: 857.649916408113  
Gauss solution: [135.23214858 136.35991034 136.63464617 136.3509446 136.43772014]  
Gauss error: 302.3252991795029  
LU solution: [135.23214858 136.35991034 136.63464617 136.3509446 136.43772014]  
LU error: 302.3252991795072
```

```
==== k = 2 ====  
Matrix A^(k):  
[[ 9.01 -1. -4. -1. -3. ]  
 [-1. 7. -1. -3. -2. ]  
 [-3. -3. 11. -2. -3. ]  
 [-4. -3. -3. 12. -2. ]  
 [-1. -3. -3. -4. 11. ]]  
Condition number: 7965.646989343022  
Gauss solution: [1522.49886827 1524.10593029 1523.95473065 1523.89769126 1524.29741965]  
Gauss error: 3404.974889682394  
LU solution: [1522.49886827 1524.10593028 1523.95473065 1523.89769126 1524.29741965]  
LU error: 3404.974889680644
```

```
==== k = 3 ====  
Matrix A^(k):  
[[11.001 -2. -2. -4. -3. ]  
 [-3. 10. -2. -3. -2. ]  
 [-2. -3. 13. -4. -4. ]  
 [-4. -4. -2. 13. -3. ]  
 [-1. -2. -1. -1. 5. ]]  
Condition number: 110562.89643639071  
Gauss solution: [20195.92134006 20197.37363431 20197.64675886 20197.45666417  
 20198.15440634]  
Gauss error: 45160.323339316186  
LU solution: [20195.9213401 20197.37363435 20197.6467589 20197.45666421  
 20198.15440638]  
LU error: 45160.32333940403
```

И получаем такой график:



LU-разложение является модификацией метода Гаусса. Поэтому, в общем и целом, можно отметить, что значение ошибок будут примерно равны.

### 3. Реализация итерационного метода решения СЛАУ (метод Зейделя, Якоби или верхней релаксации на выбор). Метод Зейделя.

Метод Зейделя представляет собой некоторую модификацию метода итераций. Основная его идея заключается в том, что при вычислении  $(k + 1)$ -го приближения неизвестной  $x_i$  учитываются уже вычисленные ранее  $(k + 1)$ -е приближения неизвестных  $x_1, x_2, \dots, x_{i-1}$ .

Пусть получена эквивалентная система (4.2). Выберем произвольно начальные приближения корней  $x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)}$ . Далее, предполагая, что  $k$ -ые приближения  $x_n^{(k)}$  корней известны, согласно Зейделю будем строить  $(k + 1)$ -е приближения корней по формулам:

$$\begin{aligned} x_1^{(k+1)} &= \beta_1 + \alpha_{12}x_2^{(k)} + \alpha_{13}x_3^{(k)} + \dots + \alpha_{1n}x_n^{(k)}, \\ x_2^{(k+1)} &= \beta_2 + \alpha_{21}x_1^{(k+1)} + \alpha_{23}x_3^{(k)} + \dots + \alpha_{2n}x_n^{(k)}, \\ &\vdots \\ x_n^{(k+1)} &= \beta_n + \alpha_{n1}x_1^{(k+1)} + \alpha_{n2}x_2^{(k+1)} + \dots + \alpha_{nn}x_n^{(k)} \quad (k=0,1,2,\dots). \end{aligned} \quad (4.5)$$

Заметим, что указанные выше условия сходимости для простой итерации остается верной для итерации по методу Зейделя. Обычно метод Зейделя дает лучшую сходимость, чем метод простой итерации, но приводит к более громоздким вычислениям.

Вот код, реализующий данный алгоритм:

```
4 def seidel(A, b, x0, tol=1e-6, max_iter=100):
5     n = len(A)
6     x = x0.copy()
7     iterations = 0
8     residual = np.linalg.norm(A @ x - b)
9
10    while residual > tol and iterations < max_iter:
11        for i in range(n):
12            x[i] = (b[i] - A[i, :i] @ x[:i] - A[i, i+1:] @ x[i+1:]) / A[i, i]
13
14            iterations += 1
15            residual = np.linalg.norm(A @ x - b)
16
17    return x, iterations, residual
```

Проведем исследование на системах с матрицами  $A^k$  :

Берем значения для  $k[1..3]$ , причем, генерируем матрицы такого вида, как и в предыдущих методах, но получаем уже такие результаты:

```
==== k = 1 ====
Matrix A^(k):
[[ 8.1 -2. -3. -1. -2. ]
 [-3.  9. -1. -1. -4. ]
 [-4. -3. 11. -2. -2. ]
 [-2. -3. -4. 13. -4. ]
 [-1. -1. -4. -3.  9. ]]
Condition number: 680.7116804044987
Gauss solution: [123.30062444 124.60856378 124.52667261 124.82729706 125.05530776]
Gauss error: 276.07657906144755
LU solution: [123.30062444 124.60856378 124.52667261 124.82729706 125.05530776]
LU error: 276.07657906144755
Seidel solution: [50.88359879 51.60891685 51.62406352 51.86301952 52.17531425]
Seidel error: 113.21833439663148

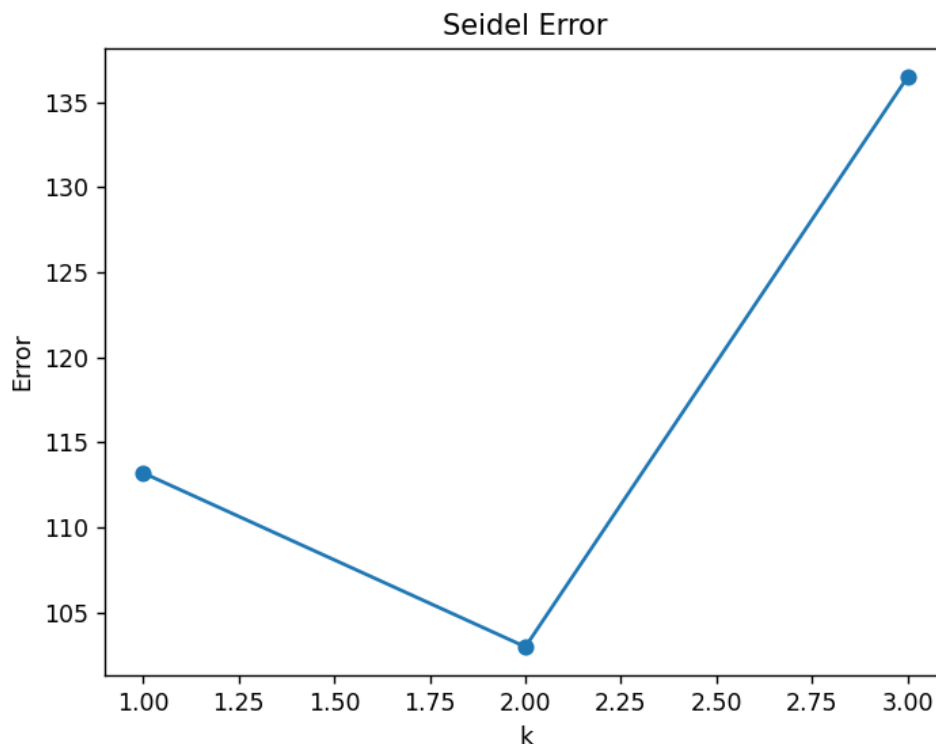
==== k = 2 ====
Matrix A^(k):
[[11.01 -3. -4. -2. -2. ]
 [-2.  8. -2. -3. -1. ]
 [-3. -3. 13. -3. -4. ]
 [-3. -4. -2. 13. -4. ]
 [-3. -3. -4. -4. 14. ]]
Condition number: 9723.445459873146
Gauss solution: [1453.00896287 1454.1975323 1454.2104528 1454.27214527 1454.32499127]
Gauss error: 3249.013261703691
LU solution: [1453.00896287 1454.1975323 1454.2104528 1454.27214527 1454.32499127]
LU error: 3249.01326170381
Seidel solution: [46.7004893 46.96494255 47.06246963 47.2059473 47.36214023]
Seidel error: 102.99271521359695
```

```

==== k = 3 ====
Matrix A^(k):
[[10.001 -2.    -4.    -2.    -2.   ]
 [-1.     5.    -2.    -1.    -1.   ]
 [-2.     -1.     8.    -1.    -4.   ]
 [-2.     -3.    -2.    10.    -3.   ]
 [-4.     -3.    -3.    -4.    14.  ]]
Condition number: 106488.05671482251
Gauss solution: [16871.20928494 16872.86521904 16872.75851743 16872.8715837
 16872.72819171]
Gauss error: 37725.79085545757
LU solution: [16871.20928496 16872.86521907 16872.75851746 16872.87158373
 16872.72819174]
LU error: 37725.790855516585
Seidel solution: [61.60938533 61.96801897 62.07660706 62.23826348 62.32317667]
Seidel error: 136.49764015588275

```

И такой график:



Обычно метод Зейделя дает лучшую сходимость, чем метод простой итерации, но приводит к более громоздким вычислениям.

Получаем в итоге такой результат в сравнении всех трех методов:

```

D:\PriMat_lab4\venv\Scripts\python.exe D:\PriMat_lab4\task4.py
Solution:
[1 2 3]
Number of iterations: 2
Residual: 0.0
==== k = 1 ====
Matrix A^(k):
[[11.1 -3.    -4.    -1.    -3.   ]
 [-4.     8.    -1.    -1.    -2.   ]
 [-3.    -1.    10.    -2.    -4.   ]
 [-1.    -1.    -4.     9.    -3.   ]
 [-2.    -1.    -4.    -3.    10.  ]]
Condition number: 845.9033091829343
Gauss solution: [170.77348066 171.86187845 172.2320442 172.56353591 172.50276243]
Gauss error: 382.34078200134735
LU solution: [170.77348066 171.86187845 172.2320442 172.56353591 172.50276243]
LU error: 382.34078200134735
Seidel solution: [54.70728815 55.26395823 55.48870698 55.8083148 55.90583069]
Seidel error: 121.7237477534876
Number of iterations: 100
Residual: 6.158360994683913

```

```

==== k = 2 ====
Matrix A^(k):
[[ 4.01 -1.  -1.  -1.  -1. ]
 [-2.  10.  -1.  -4.  -3. ]
 [-2.  -2.  11.  -3.  -4. ]
 [-3.  -3.  -4.  14.  -4. ]
 [-3.  -2.  -4.  -4.  13. ]]
Condition number: 5080.537566400623
Gauss solution: [663.01517143 664.35599092 664.44451081 664.4140485 664.47628718]
Gauss error: 1482.829342916583
LU solution: [663.01517143 664.35599092 664.44451081 664.4140485 664.47628718]
LU error: 1482.829342916474
Seidel solution: [54.59253958 54.78751051 54.93141142 55.05498366 55.25370924]
Seidel error: 120.57885365504613
Number of iterations: 100
Residual: 6.35544493374146

```

```

==== k = 3 ====
Matrix A^(k):
[[15.001 -3.  -4.  -4.  -4. ]
 [-4.  15.  -3.  -4.  -4. ]
 [-2.  -2.  11.  -4.  -3. ]
 [-4.  -2.  -3.  13.  -4. ]
 [-3.  -2.  -3.  -4.  12. ]]
Condition number: 110002.86673275416
Gauss solution: [18540.04252296 18541.06047713 18541.25939043 18541.17812419
 18541.31159927]
Gauss error: 41456.63417961985
LU solution: [18540.04252305 18541.06047722 18541.25939052 18541.17812428
 18541.31159936]
LU error: 41456.6341798192
Seidel solution: [48.74974573 48.89826037 49.09326162 49.21849745 49.43329438]
Seidel error: 107.5083758492769
Number of iterations: 100
Residual: 9.974444569133187

```

Из предоставленных данных видно, что при увеличении числа обусловленности матриц  $A^k$  увеличивается ошибка решения для всех трех методов: метода Гаусса, LU-разложения и метода Зейделя. Это связано с тем, что высокая обусловленность матрицы указывает на то, что даже небольшие изменения в правой части системы могут привести к значительным изменениям в решении. В результате получаем большие ошибки решения.

Кроме того, можно заметить, что метод Зейделя сходится медленнее, чем метод Гаусса и LU-разложение. Это видно по количеству итераций, которое для метода Зейделя составляет 100 на каждом шаге  $k$ . Это может быть связано с особенностями выбранного начального приближения и условиями сходимости метода Зейделя.

Также следует отметить, что остатки (residuals) для всех трех методов остаются относительно стабильными на каждом шаге  $k$ .

В целом, можно сделать вывод, что при увеличении числа обусловленности матрицы решение системы линейных уравнений становится менее точным, и ошибка решения увеличивается для всех методов.



#### 4. Оценка зависимости числа обусловленности и точности полученного решения в зависимости от параметра $k$ :

Для этого задания (task5.py) мы используем весь код из task4 для генерации матриц, но уже с другим шагом для  $k[1..5]$  и получаем такие результаты:

```
Solution:
[1 2 3]
Number of iterations: 2
Residual: 0.0
==== k = 1 ====
Matrix A^(k):
[[ 5.1 -2. -1. -1. -1. ]
 [-2. 6. -2. -1. -1. ]
 [-4. -4. 15. -4. -3. ]
 [-2. -4. -1. 10. -3. ]
 [-1. -2. -2. -1. 6. ]]
Condition number: 663.765899491648
Gauss error: 210.01166115825256
LU error: 210.01166115824773
Seidel error: 111.30912931481849

==== k = 2 ====
Matrix A^(k):
[[ 9.01 -2. -1. -3. -3. ]
 [-4. 14. -3. -4. -3. ]
 [-2. -4. 13. -4. -3. ]
 [-1. -2. -4. 8. -1. ]
 [-2. -1. -3. -4. 10. ]]
Condition number: 10256.35486597093
Gauss error: 4014.174526702706
LU error: 4014.1745267028987
Seidel error: 149.83274347047742
```


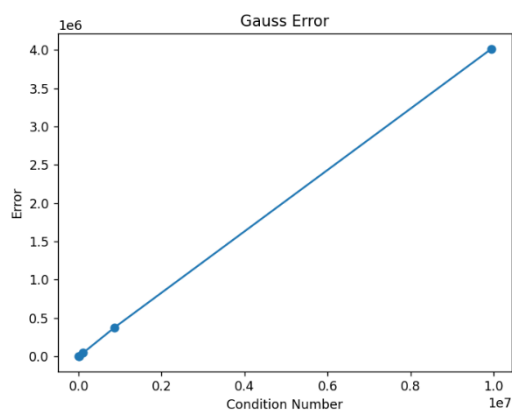
```
==== k = 3 ====
Matrix A^(k):
[[13.001 -4. -3. -4. -2. ]
 [-3. 9. -3. -1. -2. ]
 [-1. -4. 10. -1. -4. ]
 [-2. -1. -3. 8. -2. ]
 [-4. -4. -4. -4. 16. ]]
Condition number: 127381.01861419619
Gauss error: 42667.31335523672
LU error: 42667.313355252074
Seidel error: 123.4617061705256


==== k = 4 ====
Matrix A^(k):
[[11.0001 -4. -2. -4. -1. ]
 [-4. 10. -1. -3. -2. ]
 [-4. -4. 15. -3. -4. ]
 [-4. -2. -4. 14. -4. ]
 [-3. -1. -1. -3. 8. ]]
Condition number: 747513.7089762808
Gauss error: 263178.7448058398
LU error: 263178.7448058398
Seidel error: 115.90143198882215
```

```
==== k = 5 ====
Matrix A^(k):
[[11.00001 -1. -4. -3. -3. ]
 [-4. 12. -4. -2. -2. ]
 [-3. -3. 11. -4. -1. ]
 [-2. -1. -2. 8. -3. ]
 [-4. -4. -4. -4. 16. ]]
Condition number: 9259950.72820622
Gauss error: 3133982.5290741627
LU error: 3133982.529777002
Seidel error: 118.86603620621405

Condition numbers: [663.765899491648, 10256.35486597093, 127381.01861419619, 747513.7089762808, 9259950.72820622]
Gauss errors: [210.01166115825256, 4014.174526702706, 42667.31335523672, 263178.7448058398, 3133982.5290741627]
LU errors: [210.01166115824773, 4014.1745267028987, 42667.313355252074, 263178.7448058398, 3133982.529777002]
Seidel errors: [111.30912931481849, 149.83274347047742, 123.4617061705256, 115.90143198882215, 118.86603620621405]
```

И такие графики для каждого из наших методов:





Из предоставленных данных видно, что с увеличением параметра  $k$ , который отвечает за диагональное преобладание матрицы, числа обусловленности матриц  $A^{(k)}$  также увеличиваются. Это означает, что матрицы становятся более плохо обусловленными, и решение системы линейных уравнений становится более чувствительным к погрешностям в данных или округлении.

Как следствие, ошибка решения системы уравнений с помощью метода Гаусса и LU-разложения также увеличивается с увеличением числа обусловленности. Это отражено в значениях ошибок, которые растут с каждым шагом  $k$ .

Однако метод Зейделя демонстрирует более стабильную ошибку в решении, независимо от значения  $k$ . Это может быть связано с итерационным характером метода Зейделя, который позволяет достигать определенной точности независимо от числа обусловленности.

Таким образом, можно сделать вывод, что чем выше числа обусловленности матрицы, тем более неустойчивыми и неточными становятся решения системы линейных уравнений при использовании прямых методов, таких как метод Гаусса и LU-разложение. В то же время метод Зейделя остается относительно стабильным при различных значениях числа обусловленности.

##### 5. Провести аналогичные исследования на матрицах Гильберта, которые строятся согласно формуле:

$$a_{ij} = \frac{1}{i + j - 1}, \quad i, j = 1, \dots, n$$

Где  $n$  – размерность матрицы

- Матрица Гильберта является симметричной положительно определённой матрицей. Более того, матрица Гильберта является вполне положительной матрицей.
- Матрица Гильберта является примером ганкелевой матрицы.
- Определитель матриц Гильберта может быть выражен явно, как частный случай определителя Коши. Определитель матрицы Гильберта  $n \times n$  равен

$$\det(H) = \frac{c_n^4}{c_{2n}},$$

где

$$c_n = \prod_{i=1}^{n-1} i^{n-i} = \prod_{i=1}^{n-1} i!.$$

Для этого задания выберем  $n[3..6]$  и получим уже такие результаты:

```
Solution:
[1 2 3]
Number of iterations: 2
Residual: 0.0
==== n = 3 ====
Matrix Hilbert(n):
[[1.      0.5      0.33333333]
 [0.5      0.33333333 0.25     ]
 [0.33333333 0.25     0.2       ]]
Condition number: 524.0567775860644
Gauss error: 285.6676390492988
LU error: 285.6676390492988
Seidel error: 242.93521497633745

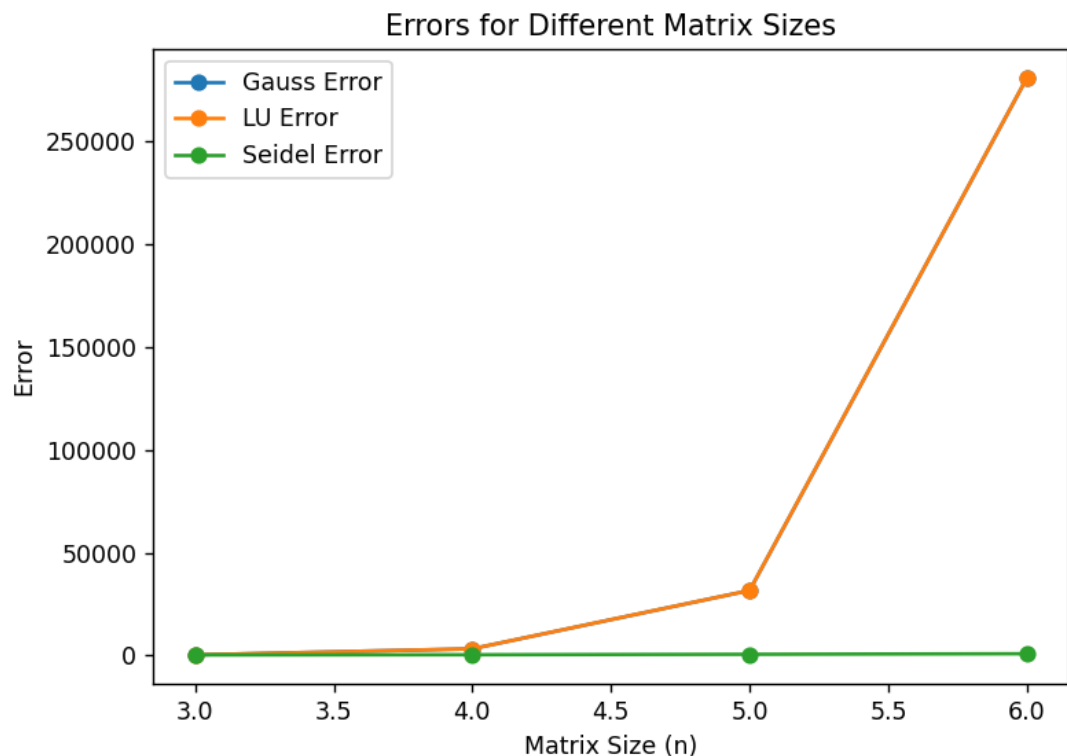
==== n = 4 ====
Matrix Hilbert(n):
[[1.      0.5      0.33333333 0.25     ]
 [0.5      0.33333333 0.25     0.2       ]
 [0.33333333 0.25     0.2       0.16666667]
 [0.25     0.2       0.16666667 0.14285714]]
Condition number: 15513.73873892924
Gauss error: 3236.7619622087523
LU error: 3236.7619622077077
Seidel error: 347.27992886821045
```

```
==== n = 5 ====
Matrix Hilbert(n):
[[1.      0.5      0.33333333 0.25     0.2       ]
 [0.5      0.33333333 0.25     0.2       0.16666667]
 [0.33333333 0.25     0.2       0.16666667 0.14285714]
 [0.25     0.2       0.16666667 0.14285714 0.125     ]
 [0.2       0.16666667 0.14285714 0.125     0.11111111]]
Condition number: 476607.2502422687
Gauss error: 31629.606067946934
LU error: 31629.60606768418
Seidel error: 571.6749603373157

==== n = 6 ====
Matrix Hilbert(n):
[[1.      0.5      0.33333333 0.25     0.2       0.16666667]
 [0.5      0.33333333 0.25     0.2       0.16666667 0.14285714]
 [0.33333333 0.25     0.2       0.16666667 0.14285714 0.125     ]
 [0.25     0.2       0.16666667 0.14285714 0.125     0.11111111]
 [0.2       0.16666667 0.14285714 0.125     0.11111111 0.1       ]
 [0.16666667 0.14285714 0.125     0.11111111 0.1       0.09090909]]
Condition number: 14951058.6424659
Gauss error: 281080.01222710055
LU error: 281080.0122302293
Seidel error: 845.977710173911
```

```
Condition numbers: [524.0567775860644, 15513.73873892924, 476607.2502422687, 14951058.6424659]
Gauss errors: [285.6676390492988, 3236.7619622087523, 31629.606067946934, 281080.01222710055]
LU errors: [285.6676390492988, 3236.7619622077077, 31629.60606768418, 281080.0122302293]
Seidel errors: [242.93521497633745, 347.27992886821045, 571.6749603373157, 845.977710173911]
```

И получим такой график сравнения каждого метода:



Можно заметить, что методы Гаусса и LU – разложения получили идентичные результаты.

Из представленных данных видно, что числа обусловленности матриц Гильберта быстро растут с увеличением размерности матрицы  $n$ . Это указывает на то, что матрицы Гильберта являются плохо обусловленными и приводят к большим ошибкам при решении систем линейных уравнений.

Метод Гаусса и LU-разложение показывают сходные значения ошибок, которые также возрастают с увеличением размерности матрицы. Это говорит о том, что оба метода чувствительны к высокому числу обусловленности и дают сопоставимую точность решения системы уравнений.

Метод Зейделя также демонстрирует увеличение ошибки с увеличением размерности матрицы, но ошибка остается сопоставимой с ошибками методов Гаусса и LU-разложения. Это может быть связано с тем, что метод Зейделя имеет итерационный характер и может достичь определенной точности, несмотря на высокое число обусловленности матрицы.

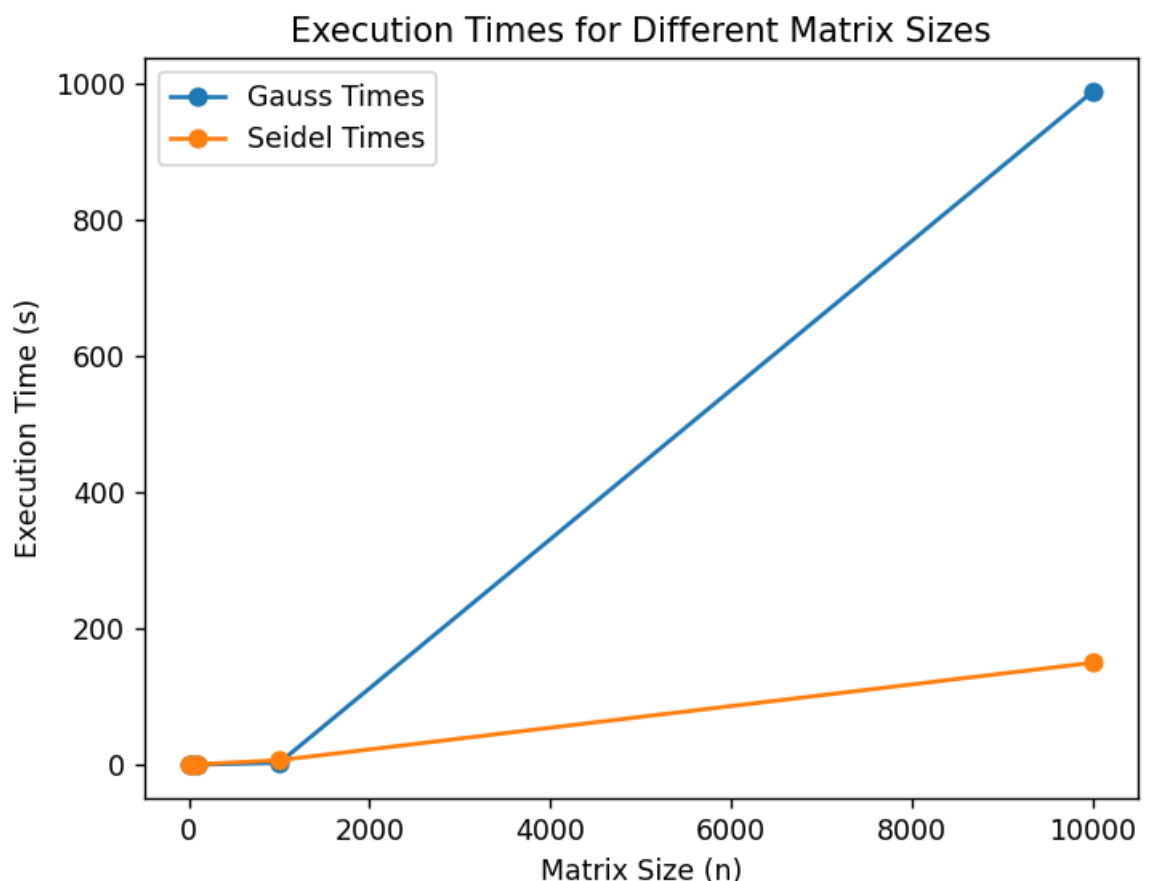
Таким образом, матрицы Гильберта являются плохо обусловленными, что ведет к большим ошибкам при решении систем линейных уравнений. Метод Зейделя остается относительно стабильным при различных размерностях матрицы, но также не избавлен от ошибок.

## 6. Сравнение между собой прямые и итерационные методы по эффективности методов в зависимости от размеров $n$ матрицы: $n \in \{10, 50, 100, 10^3, 10^4, 10^5\}$

Таким же образом строим матрицы Гилберта, что и для предыдущего задания, но уже другой размерности. Из-за увеличения размерности матрицы, время программы, затраченное на решения матриц, достигает ужасающих значений, мы не смогли дождаться для  $10^5$  размерности, но получаем результаты:

```
=== Прямой метод (Гаусс) ===  
Гаусс times: [0.0, 0.003586292266845703, 0.015044689178466797, 2.530501365661621, 988.4858531951904]  
=== Итерационный метод (Зейдель) ===  
Seidel times: [0.07261061668395996, 0.24374723434448242, 0.4872090816497803, 6.448711633682251, 149.61970233917236]
```

И получаем такой график:



Из полученных результатов видно, что время выполнения прямого метода (Гаусса) растет значительно медленнее, чем время выполнения итерационного метода (Зейделя), с увеличением размерности матрицы.